

TP3- Nettoyage et transformation d'un jeu de données CSV avec Python

Introduction :

L'objectif de ce TP3 est de concevoir un modèle Intelligent susceptible d'améliorer la prédiction des commandes en retard « *Backorder Prediction* ». Il s'agit d'un problème de classification.

Une commande en retard se produit lorsqu'un client potentiel tente de commander un produit, mais que sa commande ne peut être exécutée immédiatement parce que l'entreprise ne dispose pas du produit en question en stock. Le client est informé que le produit est en rupture de stock dans cette situation. Ce dernier a la possibilité de poursuivre la transaction, d'effectuer un achat, puis d'attendre le nouveau produit. Il peut également choisir de refuser la commande et de ne pas l'exécuter, ou de la poursuivre mais de l'annuler s'il trouve une solution plus rapide.

Description du jeu de données

Le jeu de données (DS) de cette recherche est disponible sur les bases de données de Kaggle (<https://www.kaggle.com/c/untadta/data>). Le (DS) comprend deux ensembles ; l'ensemble d'entraînement (TR) et l'ensemble du test (TS).

Prétraitement de données

1. Afficher les cinq premières lignes de TR et de TS.
2. Donner les dimensions de TR et TS.
3. Afficher le types de variables
4. Extraire les valeurs manquantes ainsi que leurs pourcentages.

Interpréter les résultats

5. Afficher les tableaux de statistique descriptive pour TS et TR
6. Proposer des solutions pour remédier au problème de valeurs manquantes

Sélection des variables pertinentes:

7. Calculer la corrélation entre les variables (Appliquer le test de khi deux pour les variables catégorielles). Si la valeur de corrélation dépasse 90% (les deux

variables sont fortement corrélées) éliminer l'une de valeurs de DS. Laquelle qu'on doit éliminer et pourquoi ? C'est quoi la nouvelle dimensionnalité de notre DS ?

8. Appliquer la méthode de PCL pour réduire la dimensionnalité.
9. Comparer les deux méthodes et interpréter les résultats.

Rééchantillonnage des données déséquilibrées

10. Afficher la distribution de la valeur de sortie. Interprétation
11. Appliquer une méthode de suréchantillonnage (*Oversampling*) pour résoudre le problème de déséquilibre.
12. Afficher la distribution de la valeur de sortie après le rééchantillonnage

Conception des modèles intelligents *Random Forest, Decision Tree* ou ANN

13. Faire un classificateur en choisissant un des trois modèles
14. Entraîner le modèle par le TR **avant** le rééchantillonnage et **après** rééchantillonnage.

Les métriques d'évaluation :

1. Calculer et afficher la matrice de confusion avant le rééchantillonnage et après rééchantillonnage.
2. Calculer les métriques ci-dessous avant le rééchantillonnage et après rééchantillonnage.
 - **Exactitude (Accur)**
 - **Précision (Precis)**
 - **Taux de vrais positifs (TPR)**
 - **Taux de vrais négatifs (TNR)**
 - **Taux de faux négatifs (FNR)**
 - **Score F1 (F1)**
 - **Spécificité (Speci)**
 - **Taux de faux positifs (FPR)**
3. Discuter les résultats et faire une synthèse