

Énoncé du problème : Clustering de documents textuels avec K-means

On dispose d'un corpus textuel extrait de Wikipédia (`people_wiki.csv`), où chaque ligne correspond à une personnalité (nom, texte descriptif).

L'objectif de ce TP est d'appliquer des techniques de **prétraitement de texte** et d'**apprentissage non supervisé** (clustering) afin de regrouper les documents selon leur similarité de contenu.

Étapes à réaliser

1. Prétraitement du texte

- Charger le jeu de données `people_wiki.csv`.
- Nettoyer le texte en supprimant :
 - o les signes de ponctuation,
 - o la casse (mettre en minuscules),
 - o les mots vides (stopwords en anglais).

2. Représentation vectorielle

- Transformer les documents en vecteurs numériques à l'aide du **TF-IDF** (Term Frequency – Inverse Document Frequency).
- Conserver le vocabulaire associé à chaque indice de la matrice TF-IDF.

3. Application de l'algorithme K-means

- Implémenter le clustering en utilisant l'algorithme **K-means** :
 - o Comparer deux méthodes d'initialisation des centroïdes : `random` et `k-means++`.
 - o Mesurer la **qualité des clusters** à l'aide de la métrique d'**hétérogénéité** (inertia).
 - o Étudier l'influence de la graine aléatoire (`random_state`) sur les résultats.

4. Choix du nombre de clusters

- Étudier la variation de l'hétérogénéité pour différentes valeurs de $k \in \{2, 10, 25, 50, 100\}$.
- Représenter graphiquement l'évolution de la métrique de qualité en fonction de k .
- Identifier un nombre de clusters pertinent.

5. Visualisation des clusters

- Pour chaque cluster obtenu :
 - o Identifier les mots les plus représentatifs (ceux ayant le poids TF-IDF le plus élevé).
 - o Lister quelques documents proches du centroïde (titres + extrait du texte).

6. Analyse

- Comparer les résultats obtenus pour **k=2** et **k=10**.
- Discuter :
 - o de la pertinence des regroupements obtenus,
 - o de l'effet de l'initialisation,
 - o du compromis entre nombre de clusters et qualité des regroupements.

Objectif final :

Construire un système capable de **regrouper automatiquement des articles de Wikipédia par similarité thématique**, et analyser la qualité des clusters obtenus en fonction des paramètres de K-means.